

Análise SRAG 2023

Predição de Evolução do Caso e Recomendações de Saúde Pública

Rodrigo · rodrigoeqv@gmail.com

Roteiro

1. **Problema e dados** — escopo da análise e características da base
2. **Decisões metodológicas** — split temporal, vazamento e métrica
3. **Cinco insights da EDA** — o que os dados revelam
4. **Modelo final** — XGBoost com tuning: AUC-PR 0,55 e AUC-ROC 0,91
5. **Equidade e calibração** — onde o modelo é forte e onde requer cautela
6. **Recomendações de saúde pública** — o passo acionável
7. **Limitações e próximos passos**

| Materiais: 7 fases, 8 notebooks, 38 figuras e 1 modelo serializado.

1. Problema e dados

Escopo da análise

#	Entrega
1	Tratamento de dados — correção e documentação
2	Análise descritiva — tendências, geografia e fatores de risco
3	Modelos de ML — predição de óbito ou cura
4	Conclusão — recomendações de saúde pública

Base: SRAG 2023 / SIVEP-Gripe — Open Data SUS.

Tamanho: 279.453 notificações, 194 colunas, 22 MB em Parquet.

Período-alvo: todo o ano de 2023 (3.114 registros fora do escopo foram descartados).

Pipeline em oito fases

```
Fase 0 – Setup e dicionário SIVEP-Gripe
Fase 1 – Profiling inicial           → notebook 01
Fase 2 – Tratamento e testes       → notebook 02 + cleaning.py + 29 testes pytest
Fase 3 – EDA descritiva             → notebook 03 + 19 figuras
Fase 4 – Feature engineering        → notebook 04 + features.py + 4 parquets
Fase 5 – Modelagem (Optuna)         → notebook 05 + models.py + best_model.joblib
Fase 6 – Avaliação e SHAP          → notebook 07 + 7 figuras
Fase 7 – Conclusões                 → notebook 08 + PDFs + README
```

Estrutura: híbrida — notebooks para a narrativa e módulo `src/` para a lógica reusável e testável.

2. Decisões metodológicas

Três decisões centrais

1. Split temporal (não aleatório)

- **Treino:** Jan-Jun 2023 (145 mil). **Teste:** Jul-Dez 2023 (103 mil).
- **Justificativa:** simula uso real do modelo e capta o shift VSR para COVID.

2. Vazamento controlado

- Excluídas: `DT_EVOLUCA`, `DT_ENCERRA` e `CRITERIO` (pós-desfecho).
- Mantidas: `UTI`, `SUPPORT_VEN` e `RAIOX_RES` (cl clinicamente relevantes e pré-desfecho).

3. Métrica primária: AUC-PR (em vez de AUC-ROC)


- Óbito é a classe rara (cerca de 10%).
- A AUC-PR é mais sensível ao desempenho na classe minoritária.
- O baseline aleatório de AUC-PR equivale à taxa de óbito, em torno de 0,10.

3. Cinco insights da EDA

Insight 1 — Pico de SRAG em 2023 foi pediátrico

- Pico em **maio/2023 (SE 21)**: 35.248 casos.
- **Vetor principal**: VSR e Influenza em **menores de 5 anos** (não COVID).
- **Magnitude**: 42% dos casos SRAG 2023 estão em 0-4 anos.
- Mediana de idade: **8 anos**.
- COVID atinge pico na SE 43 (out/nov), com magnitude bem menor.

O planejamento operacional pós-pandemia (UTI adulto, ventiladores adultos) está desalinhado em relação à carga real de 2023.



Insight 2 — Gradiente etário fortíssimo

Faixa	Letalidade
0-4	1,2%
5-19	1,5%
20-39	8,9%
40-59	17,0%
60-69	21,4%
70-79	23,9%
80+	27,7%

Variação de 23 vezes. Isoladamente, a idade é o preditor mais forte de mortalidade.

| SRAG é doença de duas pontas: incidência alta em crianças e letalidade alta em idosos.


Insight 3 — Paradoxo de Simpson na vacinação COVID

Marginal: vacinados apresentam letalidade maior (22,5% contra 11,3%, diferença de 11pp). Trata-se de artefato.

Estratificando por idade: o efeito é protetor em todos os estratos.

Faixa	Gap vacinado – não vacinado
40-59	-7,7pp
60-69	-5,2pp
70-79	-5,1pp
80+	-10,1pp

Justifica modelagem multivariada e cautela com tabelas marginais.



Insight 4 — Suporte ventilatório invasivo é o melhor preditor

SUPPORT_VEN	Letalidade
Invasivo	40,95%
Não invasivo	7,44%
Não usou	4,07%

- UTI: 18,66% contra 5,79% (3,2 vezes a letalidade).
- Aparece como top-1 e top-2 no SHAP do modelo final.

Observação: variável **hospitalar**. Reflete a resposta à gravidade observada, não apenas o estado de admissão.

Insight 5 — Comorbidades raras e graves superam as comuns

Sem ajuste por idade: a cardiopatia parece muito letal (23,1% contra 13,9%, gap de 9pp).

Com ajuste por idade: em 70-79 anos, a cardiopatia apresenta 24,4% contra 26,8% sem cardiopatia. O gap inverte para -2,4pp.

Comorbidade	Letalidade marginal	Prevalência
Hepática	30,1%	rara
Renal	26,6%	rara
Imunodepressão	24,4%	rara
Diabetes	23,6%	16%
Cardiopatia	23,1%	49%

Modelos sem IDADE_ANOS inflam o peso de cardiopatia e diabetes. As comorbidades raras e graves apresentam efeito independente mais limpo.

4. Modelo final

Oito modelos comparados — XGBoost com tuning como melhor escolha

Modelo	AUC-PR (CV 5-fold)
Dummy (estratificado)	cerca de 0,10
Regressão Logística	0,49
Random Forest tuned	0,54
XGBoost tuned	0,55
LightGBM tuned	0,54

Tuning: Optuna TPE — Random Forest com 50 trials (60 mil); XGBoost e LightGBM com 80 trials (100 mil) cada; CV 3-fold por trial.

Imbalance: `class_weight='balanced'` (LR, RF, LGBM); `scale_pos_weight=9` (XGB).


Métricas no teste temporal (Jul-Dez 2023)

Métrica	Valor	Leitura
AUC-PR	0,5531	5,4 vezes o baseline aleatório
AUC-ROC	0,9055	Discriminação elevada
Brier Score	0,0915	Calibração imperfeita

Casos no teste: 103.072, com 10.517 óbitos reais.

O threshold operacional depende do uso:


- Youden (0,319): triagem (Sen=0,873).
- Recall $\geq$ 70% (0,515): alerta clínico (F1=0,526).



Top features (SHAP)

1. **SUPPORT_VEN_ORD** — suporte invasivo.
2. **UTI** — internação em UTI.
3. **IDADE_ANOS** — gradiente monotônico.
4. Comorbidades raras e graves (hepática, renal e imunodepressão).
5. **SEM_NOT** — semana epidemiológica.


O modelo reproduz a prática clínica: gravidade aguda (ventilação, UTI) supera vulnerabilidade biológica (idade, comorbidades), que por sua vez supera a pressão sazonal sobre o sistema.



5. Equidade e calibração

Equidade — desempenho por subgrupo

- **Faixa etária:** a AUC-PR varia, mas o baseline acompanha (em todos os casos, acima do baseline).
- **Região:** desempenho uniforme nas cinco regiões.
- **Raça/cor:** sem disparidade dramática em categorias com n maior ou igual a 200.




Disparidades remanescentes podem refletir disparidade no sinal disponível no registro (a qualidade do SIVEP varia por UF), e não necessariamente viés algorítmico direto.

Calibração — quando não confiar nas probabilidades

O padrão visual é o mesmo nos dois painéis, mas as magnitudes divergem.

Célula	Real	Predito
80+ × Invasivo	69,6%	90,0%
60-69 × Invasivo	60,8%	81,8%
40-59 × Invasivo	53,8%	80,1%

O modelo ranqueia muito bem, mas as probabilidades absolutas não são confiáveis. Recalibração (Platt scaling ou regressão isotônica) é recomendada antes de uso clínico.



6. Recomendações de saúde pública

Cinco intervenções acionáveis

1. Reforço da capacidade pediátrica

Antes do pico anual de VSR (SE 17-21). Foco em UTI e leitos clínicos infantis.

2. Priorização vacinal por idade e comorbidade

Busca ativa de pacientes a partir de 70 anos com menos de quatro doses (gap real de 10pp em 80+).

3. Sistema de alerta antecipado semanal

Pipeline alimentando painel público (modelo InfoGripe). Antecipação de 2 a 4 semanas.

4. Padronização da qualidade do registro SIVEP-Gripe

Auditoria mensal por UF. Meta: menos de 30% de campos "Ignorado" em comorbidades-chave.

5. Pesquisa direcionada — **CLASSI_FIN=3** em maiores de 70 anos

Letalidade desproporcional (54 a 55%) sem agente identificado. Investigar coinfeções bacterianas.

7. Limitações e próximos passos

Limitações conhecidas

1. **Qualidade do registro SIVEP-Gripe** — cerca de 70% de missing em comorbidades; os indicadores `_MISS` mitigam, mas não resolvem.
2. **Features hospitalares como proxy de gravidade** — `UTI` e `SUPPORT_VEN` refletem a resposta ao quadro, não apenas o estado de admissão. Um modelo de triagem na chegada exige features mais restritas.
3. **Calibração imperfeita** — o Brier Score está próximo do baseline. As probabilidades absolutas não são confiáveis sem recalibração.
4. **Shift de distribuição** — o modelo foi treinado em 2023; um re-treinamento a cada seis meses é recomendado para uso contínuo.
5. **Equidade** — disparidades podem refletir disparidade no registro, e não no algoritmo. A preocupação não desaparece; muda a intervenção.

Próximos passos

Prioridade	Ação
Alta	Calibração (Platt ou isotônica) antes do uso clínico
Média	Modelo de triagem na chegada (sem features hospitalares)
Média	Pipeline em produção — Docker, API e dashboard de drift
Baixa	Validação prospectiva em 2024 (já disponível)
Baixa	Integração com InfoGripe — pipeline semanal público
Baixa	Fairness aprofundada — SHAP estratificado e métricas formais

Reprodutibilidade: `uv sync && jupyter lab ; random_state=42 ; 29 testes pytest passando.`

Síntese em uma frase

2023 foi um ano de SRAG pediátrica em volume e SRAG idosa em letalidade.

A maior alavanca de saúde pública não é melhorar mais 1 ou 2 pontos percentuais no modelo. É (1) vacinar idosos com cobertura de quatro ou mais doses, (2) reforçar a capacidade pediátrica antes do pico anual de VSR e (3) padronizar a qualidade do preenchimento do SIVEP-Gripe entre estados.

Obrigado.

Repositório · Relatório técnico · Notebooks · `models/best_model.joblib`

rodrigoeqv@gmail.com