

Sumário executivo

Este relatório documenta a análise da base **SRAG 2023** (Síndrome Respiratória Aguda Grave) do Open Data SUS / SIVEP-Gripe, abrangendo 279.453 registros de notificações em 2023. O trabalho foi conduzido em oito fases, do setup à entrega final, e produziu quatro resultados principais: um pipeline de limpeza reproduzível, uma EDA descritiva com 19 figuras, um modelo preditivo de evolução de caso (óbito ou cura) e cinco recomendações de saúde pública derivadas dos achados.

O modelo final é um XGBoost com hiperparâmetros otimizados que atinge AUC-PR de 0,5531 e AUC-ROC de 0,9055 no teste temporal de julho a dezembro de 2023. O resultado corresponde a aproximadamente 5,5 vezes o baseline aleatório (taxa-base de óbito em torno de 10%).

O achado central da análise pode ser resumido em uma linha: 2023 foi um ano de SRAG pediátrica em volume e SRAG idosa em letalidade. O pico anual ocorreu em maio (35.248 casos na semana epidemiológica 21) e foi puxado por VSR e Influenza em crianças com menos de 5 anos, enquanto a letalidade é dominada por idosos a partir dos 70 anos, chegando a 27,7% no grupo de 80+.

Em termos de recomendação de saúde pública, a maior alavanca de redução de óbitos não está na otimização adicional do modelo (já em 5,5 vezes o baseline), mas em três frentes complementares: reforço da capacidade pediátrica antes do pico anual de VSR; busca ativa de idosos a partir de 70 anos com cobertura vacinal incompleta; e padronização da qualidade do preenchimento das fichas SIVEP-Gripe entre estados.

1. Contexto e problema

1.1 Enunciado

O desafio técnico solicitou análise da base SRAG 2023 do SIVEP-Gripe com quatro entregáveis:

- Tratamento de dados** — identificar e corrigir problemas, documentando todas as etapas.
- Análise descritiva** — atributos principais, tendências temporais, distribuição geográfica, fatores de risco e comorbidades.
- Modelos de ML** — prever a evolução do caso (óbito ou cura), com transparência sobre métricas e tradeoffs.
- Conclusão** — insights e recomendações de intervenções de saúde pública.

1.2 Dataset

- Fonte:** Open Data SUS / SIVEP-Gripe — ficha de notificação compulsória de SRAG em hospitais brasileiros.
- Tamanho bruto:** 279.453 linhas e 194 colunas (22 MB em Parquet zstd).
- Período:** notificações de 2023, com pequena fração até jun/2025 (descartada na Fase 2).
- Variáveis-chave:** datas de sintoma, notificação e internação; demografia (idade, sexo, raça, UF); sintomas; comorbidades; vacinação COVID; cuidado hospitalar (UTI, suporte ventilatório); agente etiológico; e o desfecho (EVOLUCAO).

1.3 Decisões metodológicas centrais

Decisão	Escolha	Justificativa
Estrutura	Híbrida (notebooks + módulo src/)	Notebooks concentram a narrativa; módulos reúnem lógica reutilizável e testável
Storage	Parquet zstd	Cerca de 14 vezes menor que CSV; carregamento muito mais rápido
Target	EVOLUCAO ∈ {1=Cura, 2=Óbito SRAG} binário	Pergunta do desafio; descarte das categorias 3 e 9 por ruído e incerteza
Métrica primária	AUC-PR	Óbito é a classe rara (cerca de 10%); AUC-PR é mais sensível ao desempenho na classe minoritária
Split	Temporal (Jan-Jun em treino, Jul-Dez em teste)	Simula uso real e capta o shift de composição etiológica (VSR a COVID)
Vazamento	Exclusão de DT_EVOLUCA , DT_ENCERRA e CRITERIO ; manutenção de UTI , SUPORT_VEN e RAIOX_RES	Variáveis hospitalares são registradas antes do desfecho, com uso clínico legítimo
Imbalance	class_weight='balanced' e scale_pos_weight=9	Mais simples e robusto que SMOTE em dados tabulares

Reprodutibilidade	<code>random_state=42</code> fixo em <code>config.py</code>	Seed única importada por todos os módulos
-------------------	---	---

2. Tratamento de dados (Fase 2)

2.1 Etapas executadas

1. **Filtro temporal:** 3.114 linhas (1,1%) fora de 2023 foram descartadas.
2. **Drop de colunas:** 28 colunas removidas (7 totalmente vazias e 21 constantes).
3. **Casting conservador:** 21 colunas `object` (com `Decimal` mascarado) convertidas para numérico apenas quando 100% dos valores não nulos foram passíveis de parsing.
4. **Idade unificada:** `NU_IDADE_N` + `TP_IDADE` foi convertido para `IDADE_ANOS` (com 1=dias, 2=meses, 3=anos) e clip em `[0, 120]`; 7 valores aberrantes foram transformados em `NaN`.
5. **Binárias** `{1,2,9}` → `{1,0,NaN}` : o sinal de "ignorado" é preservado como missing.
6. **Decode categórico paralelo:** os códigos numéricos foram preservados (`CLASSI_FIN`) e os rótulos legíveis ficaram em coluna `_LABEL` separada (`CLASSI_FIN_LABEL`).
7. **Output:** `data/interim/srag_2023_clean.parquet` (276.339×185 colunas, 19 MB).

2.2 Decisões deliberadamente adiadas

- **Imputação de missing:** não foi feita na Fase 2 porque depende de fit em treino, o que abriria risco de data leakage. Ficou encapsulada no `Pipeline` do `sklearn` (Fase 4).
- **Filtro do target** `EVOLUCAO ∈ {1,2}` : não foi aplicado ao `parquet` persistido porque a EDA (Fase 3) precisa do universo completo. Aplica-se via `filter_modeling_target` na Fase 4.

2.3 Qualidade do código

- `src/maxpar_srag/cleaning.py` : 10 funções puras e `clean_pipeline()` para encadeamento.
- `tests/test_cleaning.py` : 29 testes `pytest` passando (0,58s).
- **Princípio:** cada decisão de tratamento tem um `markdown` explicativo no notebook 02, justificando a escolha além da descrição do que foi feito.


3. Análise descritiva (Fase 3)

Os 19 painéis cobrem as nove dimensões do enunciado. Os achados mais relevantes para política pública estão listados a seguir.

3.1 Pico de SRAG em 2023 foi pediátrico

A onda de **maio/2023 (semana epidemiológica 21)** registrou 35.248 casos, o maior pico anual. Diferentemente de 2020 a 2022, o vetor principal foi **VSR e Influenza em crianças com menos de 5 anos**, e não COVID. O pico de COVID ocorreu na SE 43 (out/nov), com magnitude bem menor.

Em magnitude, 42% dos casos SRAG 2023 estão na faixa **0-4 anos** (62 mil registros em meses, 3 mil em dias e 53 mil em anos com menos de 5). A mediana de IDADE_ANOS é de 8 anos.



{width=85%}

3.2 Gradiente etário fortíssimo na letalidade

A letalidade SRAG cresce monotonicamente da infância à terceira idade:

Faixa	Letalidade observada
0-4 anos	1,2%
5-19 anos	1,5%
20-39 anos	8,9%
40-59 anos	17,0%
60-69 anos	21,4%
70-79 anos	23,9%
80+ anos	27,7%

A variação total é de 23 vezes. Isoladamente, a idade é o preditor mais forte de mortalidade.


3.3 Paradoxo de Simpson na vacinação COVID, resolvido

A análise marginal, sem controlar pela idade, sugere que vacinados teriam letalidade maior que não vacinados (22,5% contra 11,3%, diferença de 11pp). Trata-se de um artefato: os vacinados são, em média, mais velhos.

Ao estratificar por faixa etária, o efeito da vacinação é protetor em todos os estratos com n maior ou igual a 100:

Faixa	Vacinado – Não vacinado
20-39 anos	−6,5pp
40-59 anos	−7,7pp
60-69 anos	−5,2pp
70-79 anos	−5,1pp
80+ anos	−10,1pp

O heatmap idade × doses confirma a resposta-dose: em 80+ anos, a letalidade cai de 36,8% (0 doses) para 26,1% (4 doses), com gap real de 10pp.



{width=85%}

A implicação metodológica é direta: o caso é um exemplo livro-texto de confundimento etário e justifica modelagem multivariada e cuidado com tabelas marginais, uma armadilha comum em comunicação de saúde pública.

3.4 Cuidado hospitalar como sinal de gravidade

Letalidade observada por modalidade de suporte:

SUPPORT_VEN	Letalidade
Invasivo	40,95%
Não invasivo	7,44%

Não usou	4,07%
----------	-------

UTI: 18,66% contra 5,79% (3,2 vezes a letalidade).

3.5 Comorbidades raras e graves têm efeito mais limpo

A análise univariada mostra cardiopatia com letalidade alta (23,1% contra 13,9%, gap de 9pp). Mas, ao estratificar por idade, o gap praticamente desaparece em adultos e idosos: em 70-79 anos, a letalidade com cardiopatia é de 24,4% contra 26,8% sem cardiopatia (gap de -2,4pp). O mesmo se aplica a diabetes.

Comorbidades com efeito independente mais forte (que sobrevivem à estratificação por idade) são as raras e graves: hepática (30%), renal (27%) e imunodepressão (24%).

4. Feature engineering (Fase 4)

4.1 Decisão de vazamento

A decisão metodologicamente mais importante da Fase 4 trata de vazamento de informação. O dataset SIVEP contém colunas temporariamente posteriores ao desfecho ou que revelam o desfecho diretamente:

- **Excluídas:** `DT_EVOLUCA` (data de cura ou óbito), `DT_ENCERRA` (data de fechamento da ficha) e `CRITERIO` (critério de classificação final, calculado pós-desfecho).
- **Mantidas:** `UTI`, `SUPPORT_VEN_ORD` (ordinal derivado de `SUPPORT_VEN`) e `RAIOX_RES`, todas registradas antes do desfecho e clinicamente relevantes para o quadro do paciente.

Um modelo de triagem na chegada teria features ainda mais restritas (sem `UTI` e sem `SUPPORT_VEN_ORD`), mas trata-se de um modelo separado.

4.2 Pipeline de features

- **45 features finais** após codificação (binárias, ordinais, OHE para nominais e scaler para numéricas).
- **StandardScaler** nas features numéricas, necessário para a Regressão Logística usada como baseline.
- **Cap de outlier** em `TEMPO_SINTOMA_NOTIF` ≤ 30 dias : o desvio-padrão do teste caiu de 18,6 para 6,1.
- **8 indicadores** `_MISS` para comorbidades com cerca de 70% de missing, que capturam o sinal de "não avaliado" como sinal real, distinto de "ausente".
- **Feature composta:** `RESP_SEVERIDADE` (cluster de sintomas dispneia, desconforto respiratório e saturação abaixo de 95%, identificado por correlação Pearson de 0,31 a 0,37).

4.3 Split temporal

- **Treino:** Jan-Jun/2023 — 145.407 casos, taxa de óbito de 9,7%.
- **Teste:** Jul-Dez/2023 — 103.072 casos, taxa de óbito de 10,2%.

A composição etiológica difere entre os semestres (VSR e Influenza predominam no primeiro; pico de COVID ocorre no segundo). É uma forma natural de avaliar robustez a shift de distribuição.

5. Modelagem (Fase 5)

5.1 Modelos comparados

Oito configurações foram avaliadas por CV 5-fold no treino:

#	Modelo	Papel
1	DummyClassifier	Piso mínimo (estratificado)
2	Regressão Logística	Baseline linear interpretável (<code>class_weight='balanced'</code> , <code>C=0.1</code>)
3	Random Forest (default e tuned)	Bagging — robusto a outliers e ruído
4	XGBoost (default e tuned)	Boosting — historicamente dominante em tabular
5	LightGBM (default e tuned)	Boosting leaf-wise — mais rápido


5.2 Tuning de hiperparâmetros (Optuna TPE)

- **Algoritmo:** TPE (Tree-structured Parzen Estimator), bayesiano, que aprende a distribuição de hiperparâmetros promissores.
- **CV interna por trial:** 3-fold em subset do treino (60 a 100 mil linhas), o que preserva a ordenação relativa a um custo menor.
- **Configuração final:** Random Forest com 50 trials (60 mil); XGBoost com 80 trials (100 mil); LightGBM com 80 trials (100 mil).
- **Avaliação final:** CV 5-fold no treino completo (145 mil) para estimativa honesta.

5.3 Resultados no teste temporal (Jul-Dez 2023)

O melhor modelo foi o XGBoost com tuning.

Métrica	Valor	Baseline aleatório
AUC-PR	0,5531	0,102 (taxa de óbito) — 5,4 vezes
AUC-ROC	0,9055	0,500
Brier Score	0,0915	0,0916



{width=95%}

6. Avaliação e interpretação (Fase 6)


6.1 Threshold operacional

O threshold padrão (0,5) raramente é ótimo em problemas desbalanceados. As alternativas avaliadas:

Threshold	Estratégia	Sen	Esp	Prec	F1
0,319	Youden's J	0,873	0,774	0,305	0,452
0,515	Recall ≥ 70%	0,700	—	0,422	0,526
0,500	Padrão	0,713	—	0,415	0,524

A escolha do threshold depende do uso:

- **Triagem de risco na entrada hospitalar:** Youden (0,319), com alta sensibilidade (87,3%) como prioridade. Aceita três falsos positivos para cada verdadeiro positivo, em troca de minimizar óbitos perdidos.
- **Alerta clínico para escalonamento:** Recall ≥ 70% (0,515), com melhor F1 (0,526) e precisão razoável (42%). Reduz a fadiga de alerta.




{width=85%}

6.2 SHAP — importância global das features

O TreeExplainer foi aplicado a 5.000 amostras do teste. As principais features são:

1. **SUPPORT_VEN_ORD** — suporte ventilatório invasivo (confirma a EDA: 40,95% contra 4,07%).
2. **UTI** — internação em UTI (3,2 vezes a letalidade de quem não usou UTI).
3. **IDADE_ANOS** — gradiente monotônico de risco.
4. **Comorbidades raras e graves** — hepática, renal e imunodepressão (top-10 acumulado).
5. **SEM_NOT** — semana epidemiológica (sazonalidade e pressão sobre o sistema).




{width=85%}

6.3 Calibração e discriminação

Embora a AUC-ROC seja de 0,91 (discriminação elevada), o Brier Score de 0,0915 é praticamente idêntico ao baseline ingênuo de 0,0916. Em outras palavras, o modelo ranqueia muito bem, mas as probabilidades absolutas estão mal calibradas.

O mapa de risco multivariado idade × suporte ventilatório torna isso visualmente claro: a célula 80+ × Invasivo tem letalidade real de 69,6%, mas o modelo prevê 90,0%, uma superestimação de cerca de 20pp.

Mapa de Risco Multivariado — Idade x Suporte Ventilatório



{width=95%}


Na prática, o modelo pode ser usado para ranquear pacientes em triagem (uso interno), mas as probabilidades absolutas não devem ser comunicadas a leigos sem recalibração posterior (Platt scaling ou regressão isotônica).

6.4 Equidade por subgrupo

A AUC-PR foi comparada ao baseline aleatório de cada subgrupo (taxa de óbito local):

- **Faixa etária:** o desempenho varia. Em 0-4 anos a AUC-PR é menor em valor absoluto, mas o baseline também é menor (1,2%), de modo que o modelo está mais próximo do ótimo possível.
- **Região:** o desempenho é relativamente uniforme nas cinco regiões, sem colapso em nenhuma.
- **Raça/cor:** não há disparidade dramática nas categorias com n maior ou igual a 200, mas a métrica deve ser monitorada em uso real.

Análise de Equidade por Subgrupo — Teste Jul-Dez 2023



{width=95%}

7. Recomendações de saúde pública

Cinco intervenções derivadas dos achados, cada uma com racional, responsável e impacto esperado.

7.1 Reforçar capacidade pediátrica de SRAG

Racional: 42% dos casos SRAG 2023 estão em menores de 5 anos. O pico de maio/2023 (35 mil casos por semana) foi pediátrico. A capacidade adulta abundante no pós-pandemia não cobre essa carga.

Ação:

- Mapeamento de leitos pediátricos de UTI e clínicos disponíveis por região e simulação do pico de VSR (modelo histórico SE 17-21).
- Ampliação dos protocolos de transferência inter-municipal para evitar saturação local em capitais de menor porte.
- Vacinação infantil contra Influenza com cobertura ampliada antes de abril.

Responsável: secretarias estaduais de saúde e Ministério da Saúde (DGSI).

7.2 Priorização vacinal por perfil idade × comorbidade

Racional: o paradoxo de Simpson mostrou que a vacinação protege em todos os estratos, com maior magnitude absoluta em 80+ (gap real de 10pp). A cobertura em maiores de 70 anos com 4+ doses ainda é desigual.

Ação:

- Cruzamento dos registros do PNI (Programa Nacional de Imunização) com cadastros do SUS para identificar idosos a partir de 70 anos com menos de quatro doses e priorizar a busca ativa.
- Priorização de comorbidades raras e graves (renal, hepática, imunodepressão) para reforço anual, independentemente da idade.
- Comunicação com linguagem estratificada por idade, evitando tabelas marginais confundidoras.

Responsável: PNI / Ministério da Saúde e Atenção Primária.

7.3 Sistema de alerta antecipado

Racional: o modelo (AUC-ROC de 0,91) discrimina muito bem quem morre. Combinado com SEM_NOT, pode ser usado para alertar antecipadamente quais semanas e UFs concentram maior pressão.

Ação:

- Pipeline semanal: a cada segunda-feira, o modelo processa as fichas SIVEP da semana anterior e emite um "score regional de SRAG" — média das probabilidades preditas

- ponderada pelo volume.
- Painel público nos moldes do InfoGripe (Fiocruz) com previsão de pico de 2 a 4 semanas à frente.
- Threshold operacional de Youden (0,319) para acionar alertas em UFs específicas.

Responsável: Centro de Operações de Emergências (COE) e Fiocruz / InfoGripe.

7.4 Padronização da qualidade do registro SIVEP-Gripe

Racional: os cerca de 70% de missing em comorbidades não significam que os pacientes não as tinham; significam que a ficha foi preenchida apressadamente. A disparidade de letalidade por UF (AP 2,4% contra TO 21,8%) é parcialmente explicada pela qualidade do registro, e não apenas pela qualidade do cuidado.

Ação:

- Auditoria amostral mensal de fichas SIVEP por UF, com meta de menos de 30% de campos "Ignorado" em comorbidades-chave.
- Treinamento dos profissionais de notificação em hospitais com piores indicadores de qualidade.
- Uso dos indicadores _MISS como sinal de qualidade do hospital, e não apenas como feature do modelo.

Responsável: SVS / MS e secretarias estaduais.

7.5 Pesquisa direcionada: SRAG por outro agente etiológico em idosos

Racional: casos com CLASSI_FIN=3 (n próximo de 3,6 mil) têm letalidade desproporcional em maiores de 70 anos (54 a 55%). Há possibilidade de coinfeções bacterianas pós-virais ou agentes raros e graves.

Ação:

- Estudo retrospectivo dirigido, com revisão de prontuário em 200 a 300 dessas fichas.
- Coleta sistemática de cultura e PCR ampliado nos casos a partir de 70 anos com SRAG e teste viral negativo.
- Avaliação de protocolo de antibioticoterapia empírica precoce em SRAG 70+ enquanto o agente é investigado.

Responsável: Instituto Evandro Chagas, redes de hospitais universitários e Sociedades de Pneumologia e Geriatria.

8. Limitações e próximos passos

8.1 Limitações conhecidas

1. **Qualidade do registro SIVEP-Gripe.** Os cerca de 70% de missing em comorbidades degradam tanto a EDA quanto o modelo. Os indicadores `_MISS` mitigam parcialmente o problema ao capturar o sinal de "não avaliado", mas não resolvem o viés sistemático.
2. **Features hospitalares como proxy de gravidade.** `SUPPORT_VEN_ORD` e `UTI` registram a resposta ao quadro clínico, e não apenas o estado de admissão. Um modelo de triagem na chegada exigiria features restritas ao pré-internação, em projeto separado.
3. **Calibração imperfeita.** O Brier Score está próximo do baseline e as probabilidades absolutas não devem ser comunicadas a leigos sem recalibração (Platt scaling ou regressão isotônica).
4. **Shift de distribuição.** O split temporal capta a sazonalidade de 2023. A generalização para 2024 em diante exige re-treinamento periódico (recomendado a cada 6 meses) e monitoramento de drift.
5. **Equidade.** Disparidades por raça e região podem refletir disparidade no sinal disponível no registro, e não necessariamente viés algorítmico direto. Isso não elimina a preocupação; muda a intervenção, do recalibrar o modelo para melhorar o registro.
6. **Variáveis ausentes.** Status socioeconômico, plano de saúde e distância ao hospital são potencialmente preditivos, mas não estão presentes na ficha SIVEP.

8.2 Próximos passos

1. **Calibração:** Platt scaling ou regressão isotônica antes do uso clínico.
2. **Modelo de triagem na chegada** (sem features hospitalares): espera-se AUC-PR menor (talvez entre 0,30 e 0,40), mas com utilidade operacional maior.
3. **Pipeline em produção:** containerização (Docker), API REST e dashboard de monitoramento de drift (Evidently ou whylabs).
4. **Validação prospectiva:** execução em casos de 2024 (já disponíveis) e comparação entre previsão e realidade.
5. **Integração com InfoGripe:** pipeline semanal alimentando o painel público.
6. **Equidade aprofundada:** análise SHAP estratificada por região e métricas formais de fairness (equal opportunity e demographic parity).

9. Conclusão

O projeto entregou o ciclo completo de ciência de dados aplicada a um problema de saúde pública. Dados brutos do SIVEP-Gripe foram transformados em insights descritivos, em um modelo preditivo honesto e em recomendações de intervenção acionáveis.

Em termos quantitativos, o XGBoost com tuning atingiu AUC-PR de 0,5531 e AUC-ROC de 0,9055, ou 5,5 vezes o baseline aleatório. As top features pelo SHAP são coerentes com a prática clínica: suporte ventilatório, UTI e idade.

O insight central é que 2023 foi um ano de SRAG pediátrica em volume e SRAG idosa em letalidade. O paradoxo de Simpson na vacinação COVID é um lembrete potente do valor da estratificação na comunicação de saúde pública.

A direção estratégica recomendada é clara. A maior alavanca de redução de óbitos não está em otimizar 1 ou 2 pontos percentuais adicionais na AUC-PR, mas em três frentes complementares: vacinar idosos com cobertura completa, reforçar a capacidade pediátrica antes do pico anual de VSR e padronizar a qualidade do preenchimento das fichas entre estados.

Quanto à reprodutibilidade, todo o projeto é executável a partir de um clone limpo (`uv sync && jupyter lab`). Os 29 testes pytest em `tests/test_cleaning.py` passam, o `random_state=42` é fixo e o pipeline final está serializado em `models/best_model.joblib` .

Anexos: notebooks 01 a 08 com narrativa completa; `reports/figures/` com 38 ou mais figuras nomeadas por fase.