

Análise SRAG 2023 — Relatório Técnico

Desafio Maxpar · Vaga Cientista de Dados Sênior

Rodrigo · rodrigoeqv@gmail.com

Maio de 2026

Sumario

Sumário executivo

1. Contexto e problema

1.1 Enunciado

1.2 Dataset

1.3 Decisões metodológicas centrais

2. Tratamento de dados (Fase 2)

2.1 Etapas executadas

2.2 Decisões deliberadamente adiadas

2.3 Qualidade do código

3. Análise descritiva (Fase 3)

3.1 Pico de SRAG em 2023 foi pediátrico

3.2 Gradiente etário fortíssimo na letalidade

3.3 Paradoxo de Simpson na vacinação COVID, resolvido

3.4 Cuidado hospitalar como sinal de gravidade

3.5 Comorbidades raras-e-graves têm efeito mais limpo

4. Feature engineering (Fase 4)

4.1 Decisão de vazamento

4.2 Pipeline de features

4.3 Split temporal

5. Modelagem (Fase 5)

5.1 Modelos comparados

5.2 Tuning de hiperparâmetros (Optuna TPE)

5.3 Resultados no teste temporal (Jul-Dez 2023)

6. Avaliação e interpretação (Fase 6)

6.1 Threshold operacional

6.2 SHAP — importância global das features

6.3 Calibração e discriminação

6.4 Equidade por subgrupo

7. Recomendações de saúde pública

7.1 Reforçar capacidade pediátrica de SRAG

7.2 Priorização vacinal por perfil idade × comorbidade

7.3 Sistema de alerta antecipado

7.4 Padronização da qualidade do registro SIVEP-Gripe

7.5 Pesquisa direcionada: SRAG por outro agente etiológico em idosos

8. Limitações e próximos passos

8.1 Limitações conhecidas

8.2 Próximos passos

9. Conclusão

Sumário executivo

Este relatório documenta a análise da base **SRAG 2023** (Síndrome Respiratória Aguda Grave) do Open Data SUS / SIVEP-Gripe, abrangendo 279.453 registros de notificações em 2023. O trabalho foi conduzido em 8 fases — do setup à entrega final — produzindo (1) um pipeline de limpeza reproduzível, (2) uma EDA descritiva com 19 figuras, (3) um modelo preditivo de evolução de caso (óbito × cura), e (4) cinco recomendações de saúde pública derivadas dos achados.

Resultado central do modelo: XGBoost tuned, AUC-PR 0.5531 e AUC-ROC 0.9055 no teste temporal Jul-Dez/2023 — aproximadamente **5,5× acima do baseline aleatório** (taxa-base de óbito $\approx$ 10%).

Achado central da análise: 2023 foi um ano de **SRAG pediátrica em volume e SRAG idosa em letalidade** — o pico anual em maio (35.248 casos na semana epidemiológica 21) foi puxado por VSR e Influenza em crianças <5 anos, enquanto a letalidade é dominada por idosos 70+ (até 27,7% em 80+).

Recomendação central de saúde pública: a maior alavanca de redução de óbitos não está na otimização adicional do modelo (já em 5,5× o baseline) mas em: (a) reforço da capacidade pediátrica antes do pico anual de VSR; (b) busca ativa de idosos 70+ com cobertura vacinal incompleta; e (c) padronização da qualidade do preenchimento das fichas SIVEP-Gripe entre estados.

1.1 Enunciado

O desafio técnico solicitou análise da base SRAG 2023 do SIVEP-Gripe com quatro entregáveis:

- 1. **Tratamento de dados** — identificar e corrigir problemas, documentando todas as etapas.
- 2. **Análise descritiva** — atributos principais, tendências temporais, distribuição geográfica, fatores de risco e comorbidades.
- 3. **Modelos de ML** — prever evolução do caso (óbito × cura) com transparência sobre métricas e tradeoffs.
- 4. **Conclusão** — insights e recomendações de intervenções de saúde pública.

1.2 Dataset

- **Fonte:** Open Data SUS / SIVEP-Gripe — ficha de notificação compulsória de SRAG em hospitais brasileiros.
- **Tamanho bruto:** 279.453 linhas × 194 colunas (22 MB em Parquet zstd).
- **Período:** notificações de 2023 (com pequena fração até jun/2025 — descartada na Fase 2).
- **Variáveis-chave:** datas de sintoma/notificação/internação, demografia (idade, sexo, raça, UF), sintomas, comorbidades, vacinação COVID, cuidado hospitalar (UTI, suporte ventilatório), agente etiológico, e o desfecho (EVOLUCAO).

1.3 Decisões metodológicas centrais

Decisão	Escolha	Por quê
Estrutura	Híbrida (notebooks + módulo src/)	Narrativa nos notebooks; lógica reutilizável e testável em módulos
Storage	Parquet zstd	~14× menor que CSV, carregamento muito mais rápido
Target	EVOLUCAO ∈ {1=Cura, 2=Óbito SRAG} binário	Pergunta do desafio; descartamos 3 e 9 (ruído/incerteza)
Métrica primária	AUC-PR	Óbito é a classe rara (~10%); AUC-PR é mais sensível ao desempenho na classe minoritária
Split	Temporal (Jan-Jun treino / Jul-Dez teste)	Simula uso real; capta shift de composição etiológica VSR→COVID
Vazamento	Excluir DT_EVOLUCA , DT_ENCERRA , CRITERIO ; manter UTI , SUPORT_VEN , RAIOX_RES	Variáveis hospitalares acontecem antes do desfecho — uso clínico legítimo
Imbalance	class_weight='balanced' / scale_pos_weight=9	Mais simples e robusto que SMOTE em dados tabulares
Reprodutibilidade	random_state=42 fixo em config.py	Seed única importada por todos os módulos

2.1 Etapas executadas

1. **Filtro temporal** — descartadas 3.114 linhas (1,1%) fora de 2023.
2. **Drop de colunas** — 28 colunas removidas (7 totalmente vazias + 21 constantes).
3. **Casting conservador** — 21 colunas `object` (`Decimal` mascarado) convertidas para numérico apenas se 100% dos valores não-nulos parseassem.
4. **Idade unificada** — `NU_IDADE_N` + `TP_IDADE` → `IDADE_ANOS` (1=dias, 2=meses, 3=anos), com clip `[0, 120]`. 7 valores aberrantes viraram NaN.
5. **Binárias** `{1, 2, 9}` → `{1, 0, NaN}` — preservando o sinal de "ignorado" como missing.
6. **Decode categórico paralelo** — códigos numéricos preservados (`CLASSI_FIN`); rótulos legíveis em coluna `_LABEL` separada (`CLASSI_FIN_LABEL`).
7. **Output** — `data/interim/srag_2023_clean.parquet` (276.339×185 , 19 MB).

2.2 Decisões deliberadamente adiadas

- **Imputação de missing:** não feita na Fase 2 (depende de fit em treino — risco de data leakage). Encapsulada no `Pipeline` do sklearn (Fase 4).
- **Filtro do target** `EVOLUCAO ∈ {1, 2}` : não aplicado ao parquet persistido — Fase 3 (EDA) precisa do universo completo. Aplicado via `filter_modeling_target` na Fase 4.

2.3 Qualidade do código

- `src/maxpar_srag/cleaning.py` — 10 funções puras + `clean_pipeline()` para encadeamento.
- `tests/test_cleaning.py` — 29 testes pytest verdes (0.58s).
- **Princípio:** cada decisão de tratamento tem markdown "Por quê" no notebook 02 — não é apenas descritivo, é a justificativa que distingue um candidato sênior.


3. Análise descritiva (Fase 3)

Os 19 painéis cobrem as 9 dimensões do enunciado. Os achados mais carregados de implicação para política pública estão abaixo.

3.1 Pico de SRAG em 2023 foi pediátrico

A onda de **maio/2023 (semana epidemiológica 21)** registrou 35.248 casos — o maior pico anual. Diferentemente de 2020–2022, o vetor principal foi **VSR e Influenza em crianças <5 anos**, não COVID. O pico de COVID ocorreu na SE 43 (out/nov), com magnitude bem menor.

Magnitude: 42% dos casos SRAG 2023 estão na faixa **0-4 anos** (62k em meses + 3k em dias + 53k em anos <5). Mediana de `IDADE_ANOS` = 8 anos.



3.2 Gradiente etário fortíssimo na letalidade

A letalidade SRAG cresce monotonicamente da infância à terceira idade:

Faixa	Letalidade observada
0-4 anos	1,2%
5-19 anos	1,5%
20-39 anos	8,9%
40-59 anos	17,0%
60-69 anos	21,4%
70-79 anos	23,9%
80+ anos	27,7%

23× de variação. A idade é, isoladamente, o preditor mais forte de mortalidade.


3.3 Paradoxo de Simpson na vacinação COVID, resolvido

Análise marginal (sem controlar idade) sugere que **vacinados têm letalidade maior** que não-vacinados (22,5% vs 11,3%, +11pp). Isso é um artefato — os vacinados são, em média, mais velhos.

Estratificando por faixa etária, o efeito da vacinação é **protetor em todos os estratos** com n≥100:

Faixa	Vacinado – Não vacinado
20-39 anos	–6,5pp
40-59 anos	–7,7pp
60-69 anos	–5,2pp
70-79 anos	–5,1pp
80+ anos	–10,1pp

O heatmap idade × doses confirma **resposta-dose**: em 80+ anos, letalidade cai de 36,8% (0 doses) para 26,1% (4 doses) — gap real de 10pp.



Implicação metodológica: exemplo livro-texto de confundimento etário. Justifica modelagem multivariada e cuidado com leitura ingênua de tabelas marginais — armadilha comum em comunicação de saúde pública.

3.4 Cuidado hospitalar como sinal de gravidade

Letalidade observada por modalidade de suporte:

SUPPORT_VEN	Letalidade
Invasivo	40,95%
Não invasivo	7,44%
Não usou	4,07%

UTI: 18,66% vs 5,79% (3,2× letalidade).

3.5 Comorbidades raras-e-graves têm efeito mais limpo

Análise univariada mostra cardiopatia com letalidade alta (23,1% vs 13,9% — gap +9pp). Mas estratificando por idade, **o gap praticamente desaparece** em adultos/idosos (em 70-79 anos: com cardiopatia 24,4% vs sem 26,8% — gap –2,4pp). O mesmo vale para diabetes.

Comorbidades com **efeito independente mais forte** (sobrevivem à estratificação por idade) são as raras-e-graves: hepática (30%), renal (27%), imunodepressão (24%).

4.1 Decisão de vazamento

A decisão metodologicamente mais importante da Fase 4. O dataset SIVEP tem várias colunas que são **temporariamente posteriores** ao desfecho ou que **revelam o desfecho diretamente**:

- **✗ Excluídas:** `DT_EVOLUCA` (data de cura/óbito), `DT_ENCERRA` (data de fechamento da ficha), `CRITERIO` (critério de classificação final — calculado pós-desfecho).
- **✓ Mantidas:** `UTI`, `SUPPORT_VEN_ORD` (numérico ordinal derivado de `SUPPORT_VEN`), `RAIOX_RES` — todas registradas **antes** do desfecho e clinicamente relevantes para o quadro do paciente.

Um modelo de **triagem na chegada** teria features ainda mais restritivas (sem `UTI` / `SUPPORT_VEN_ORD`) — mas isso é um modelo separado.

4.2 Pipeline de features

- **45 features finais** após codificação (binárias, ordinais, OHE para nominais, scaler para numéricas).
- **StandardScaler** em features numéricas — necessário para Regressão Logística usada como baseline.
- **Cap de outlier** em `TEMPO_SINTOMA_NOTIF ≤ 30 dias` — std do teste caiu de 18,6 para 6,1.
- **8 indicadores** `_MISS` para comorbidades com ~70% missing — capturam o sinal de "não-avaliado" como sinal real, separado de "ausente".
- **Feature composta:** `RESP_SEVERIDADE` (cluster de sintomas dispneia + desconforto + saturação <95% identificado por correlação Pearson 0,31-0,37).

4.3 Split temporal

- **Treino:** Jan-Jun/2023 — 145.407 casos · taxa de óbito 9,7%.
- **Teste:** Jul-Dez/2023 — 103.072 casos · taxa de óbito 10,2%.

A composição etiológica difere entre os semestres (VSR/Influenza no 1º; pico COVID no 2º) — uma forma natural de avaliar robustez a shift de distribuição.

5.1 Modelos comparados

Oito configurações avaliadas por CV 5-fold no treino:

#	Modelo	Papel
1	DummyClassifier	Piso mínimo (estratificado)
2	Regressão Logística	Baseline linear interpretável (<code>class_weight='balanced'</code> , <code>C=0.1</code>)
3	Random Forest (default + tuned)	Bagging — robusto a outliers e ruído
4	XGBoost (default + tuned)	Boosting — historicamente dominante em tabular
5	LightGBM (default + tuned)	Boosting leaf-wise — mais rápido

5.2 Tuning de hiperparâmetros (Optuna TPE)


- **Algoritmo:** TPE (Tree-structured Parzen Estimator) — bayesiano, aprende distribuição de hiperparâmetros promissores.
- **CV interna por trial:** 3-fold em subset do treino (60-100k linhas) — preserva ordenação relativa com custo menor.
- **Configuração final:** RF com 50 trials (60k); XGBoost com 80 trials (100k); LightGBM com 80 trials (100k).
- **Avaliação final:** CV 5-fold no treino completo (145k) para estimativa honesta.

5.3 Resultados no teste temporal (Jul-Dez 2023)

Vencedor: XGBoost tuned

Métrica	Valor	Baseline aleatório
AUC-PR	0.5531	0.102 (taxa de óbito) → 5,4× ganho
AUC-ROC	0.9055	0.500
Brier Score	0.0915	0.0916

Desempenho do XGBoost — Teste Jul-Dez 2023



Curvas PR e ROC


6.1 Threshold operacional

O threshold padrão (0.5) raramente é ótimo em problemas desbalanceados. Avaliamos:

Threshold	Estratégia	Sen	Esp	Prec	F1
0.319	Youden's J	0.873	0.774	0.305	0.452
0.515	Recall ≥ 70%	0.700	—	0.422	0.526
0.500	Padrão	0.713	—	0.415	0.524

Escolha do threshold operacional depende do uso:


- **Triagem de risco em entrada hospitalar:** Youden (0.319) — alta sensibilidade (87,3%) é prioritária; aceita 3 falsos positivos para cada verdadeiro positivo para minimizar óbitos perdidos.
- **Alerta clínico para escalonamento:** Recall ≥ 70% (0.515) — melhor F1 (0.526) e precisão razoável (42%); reduz fadiga de alerta.



6.2 SHAP — importância global das features

TreeExplainer aplicado a 5.000 amostras do teste. Top features:


1. **SUPPORT_VEN_ORD** — suporte ventilatório invasivo (confirma EDA: 40,95% vs 4,07%)
2. **UTI** — internação em UTI (3,2× a letalidade de não-UTI)
3. **IDADE_ANOS** — gradiente monotônico de risco
4. **Comorbidades raras-graves** — hepática, renal, imunodepressão (top-10 cumulativo)
5. **SEM_NOT** — semana epidemiológica (sazonalidade + pressão sobre o sistema)



6.3 Calibração e discriminação

Embora a AUC-ROC seja 0.91 (excelente discriminação), o **Brier Score de 0.0915 é praticamente idêntico ao baseline ingênuo de 0.0916**. Isto significa que o modelo **ranqueia muito bem** mas as **probabilidades absolutas estão mal calibradas**.

O mapa de risco multivariado idade × suporte ventilatório (figura abaixo) torna isso visualmente claro: a célula 80+ × Invasivo tem letalidade real de 69,6% mas o modelo prediz 90,0% — superestimação de ~20pp.



Mapa de risco multivariado — real vs predito


Implicação prática: o modelo pode ser usado para **ranquear** pacientes em triagem (uso interno), mas as **probabilidades absolutas não devem ser comunicadas a leigos** sem recalibração posterior (Platt scaling ou isotonic regression).

6.4 Equidade por subgrupo

AUC-PR comparada ao baseline aleatório do subgrupo (taxa de óbito local):

- **Faixa etária:** desempenho varia. Em 0-4 anos a AUC-PR é menor em valor absoluto, mas o baseline também é menor (1,2%) — o modelo está "mais perto do ótimo possível".
- **Região:** desempenho relativamente uniforme nas 5 regiões — não há colapso em nenhuma.
- **Raça/cor:** sem disparidade dramática nas categorias com $n \geq 200$, mas deve ser monitorado em uso real.

Análise de Equidade por Subgrupo — Teste Jul-Dez 2023



Análise de equidade por subgrupo

7. Recomendações de saúde pública

Cinco intervenções derivadas dos achados, cada uma com racional, responsável e impacto esperado.

7.1 Reforçar capacidade pediátrica de SRAG

Racional: 42% dos casos SRAG 2023 estão em <5 anos. O pico de maio/2023 (35k casos/semana) foi pediátrico. A capacidade adulta abundante no pós-pandemia não cobre essa carga.

Ação:

- Mapear leitos pediátricos UTI e clínicos disponíveis por região e simular pico de VSR (modelo histórico SE 17-21).
- Ampliar protocolos de transferência inter-municipal para evitar saturação local em capitais de menor porte.
- Vacinação infantil contra Influenza com cobertura ampliada antes de abril.

Responsável: secretarias estaduais de saúde + Ministério da Saúde (DGSI).

7.2 Priorização vacinal por perfil idade × comorbidade

Racional: o paradoxo de Simpson mostrou que a vacinação protege em todos os estratos, com maior magnitude absoluta em 80+ (gap real de 10pp). A cobertura em >70 com 4+ doses ainda é desigual.

Ação:

- Cruzar registros do PNI (Programa Nacional de Imunização) com cadastros do SUS para identificar idosos 70+ com <4 doses e priorizar busca ativa.
- Priorizar comorbidades raras-graves (renal, hepática, imuno) para reforço anual independente da idade.
- Comunicar usando linguagem estratificada por idade (evitar tabelas marginais confundidoras).

Responsável: PNI/Ministério da Saúde + Atenção Primária.

7.3 Sistema de alerta antecipado

Racional: o modelo (AUC-ROC 0.91) discrimina muito bem quem morre. Combinado com SEM_NOT, pode ser usado para alertar antecipadamente as semanas e UFs de maior pressão.

Ação:

- Pipeline semanal: a cada segunda-feira, o modelo processa as fichas SIVEP da semana anterior e emite um "score regional de SRAG" — média das probabilidades preditas ponderada por volume.
- Painel público nos moldes do InfoGripe (Fiocruz) com previsão de pico 2-4 semanas à frente.
- Threshold operacional Youden (0.319) para acionar alertas em UFs específicas.

Responsável: Centro de Operações de Emergências (COE) + Fiocruz / InfoGripe.

7.4 Padronização da qualidade do registro SIVEP-Gripe

Racional: ~70% de missing em comorbidades não significa que os pacientes não as tinham — significa que a ficha foi preenchida apressadamente. A disparidade de letalidade por UF (AP 2,4% vs TO 21,8%) é parcialmente explicada por qualidade do registro, não apenas qualidade do cuidado.

Ação:

- Auditoria amostral mensal de fichas SIVEP por UF — meta de <30% de campos "Ignorado" em comorbidades-chave.

- Treinar profissionais de notificação em hospitais com piores indicadores de qualidade.
- Usar indicadores `_MISS` como sinal de qualidade do hospital — não apenas como feature do modelo.

Responsável: SVS/MS + secretarias estaduais.

7.5 Pesquisa direcionada: SRAG por outro agente etiológico em idosos

Racional: casos com `CLASSI_FIN=3` ($n \approx 3.6k$) têm letalidade desproporcional em 70+ (54-55%). Possivelmente coinfeções bacterianas pós-virais ou agentes raros graves.

Ação:

- Estudo retrospectivo dirigido com revisão de prontuário em 200-300 dessas fichas.
- Coleta sistemática de cultura/PCR ampliado nos casos 70+ com SRAG e teste viral negativo.
- Considerar protocolo de antibioticoterapia empírica precoce em SRAG 70+ enquanto se investiga agente.

Responsável: Instituto Evandro Chagas + redes de hospitais universitários + Sociedades de Pneumologia/Geriatria.

8.1 Limitações conhecidas

1. **Qualidade do registro SIVEP-Gripe.** ~70% de missing em comorbidades degrada tanto EDA quanto modelo. Indicadores `_MISS` mitigam parcialmente — capturam o sinal de "não-avaliado" — mas não resolvem o viés sistemático.
2. **Features hospitalares como proxy de gravidade.** `SUPPORT_VEN_ORD` e `UTI` registram a **resposta** ao quadro clínico, não apenas o estado de admissão. Um modelo de triagem na chegada exigiria features só de pré-internação — projeto separado.
3. **Calibração imperfeita.** Brier $\approx$ baseline; probabilidades absolutas não devem ser comunicadas a leigos sem recalibração (Platt scaling / isotonic regression).
4. **Shift de distribuição.** Split temporal capta sazonalidade 2023. Generalização para 2024+ exige re-treinamento periódico (recomendado a cada 6 meses) e monitoramento de drift.
5. **Equidade.** Disparidades por raça/região podem refletir disparidade no sinal disponível no registro, não necessariamente viés algorítmico direto. Não elimina a preocupação — muda a intervenção (melhorar registro vs. recalibrar modelo).
6. **Variáveis ausentes.** Status socioeconômico, plano de saúde, distância ao hospital — potencialmente preditivas mas não presentes na ficha SIVEP.

8.2 Próximos passos

1. **Calibração:** Platt scaling ou isotonic regression antes de uso clínico.
2. **Modelo de triagem na chegada** (sem features hospitalares): esperar AUC-PR menor (talvez 0.30-0.40) mas mais útil operacionalmente.
3. **Pipeline em produção:** containerização (Docker), API REST, dashboard de monitoramento de drift (Evidently ou whylabs).
4. **Validação prospectiva:** rodar em casos 2024 (já disponíveis) e comparar previsão $\times$ realidade.
5. **Integração com InfoGripe:** pipeline semanal alimentando o painel público.
6. **Equidade aprofundada:** análise SHAP estratificada por região + métricas de fairness (equal opportunity, demographic parity).

9. Conclusão

O projeto entregou o ciclo completo de ciência de dados aplicada a um problema de saúde pública: dados brutos do SIVEP-Gripe foram transformados em insights descritivos, um modelo preditivo honesto, e recomendações de intervenção acionáveis.

Resultados quantitativos: XGBoost tuned com AUC-PR 0.5531 e AUC-ROC 0.9055 — 5,5× acima do baseline aleatório. Top features (SHAP) coerentes com a sabedoria clínica: suporte ventilatório, UTI, idade.

Insight central: 2023 foi um ano de SRAG pediátrica em volume e SRAG idosa em letalidade. O paradoxo de Simpson na vacinação COVID é um lembrete potente do valor da estratificação na comunicação de saúde pública.

Direção estratégica: a maior alavanca de redução de óbitos não está em otimizar 1-2pp adicionais na AUC-PR, mas em (a) vacinar idosos com cobertura completa, (b) reforçar capacidade pediátrica antes do pico anual de VSR, e (c) padronizar a qualidade do preenchimento das fichas entre estados.

Reprodutibilidade: todo o projeto é executável a partir de um clone limpo (`uv sync && jupyter lab`). 29 testes pytest verdes em `tests/test_cleaning.py` . `random_state=42` fixo. Pipeline final serializado em `models/best_model.joblib` .

Anexos: notebooks 01 a 08 com narrativa completa; `reports/figures/` com 38+ figuras nomeadas por fase; `STATUS.md` com histórico de decisões tomadas no caminho.